



Universidade Federal de Pernambuco
Centro de Informática

Graduação em Ciência da Computação

<TÍTULO DA OBRA>

Guilherme Leite Moreira de Paiva

Trabalho de Graduação

Recife

<DATA DA DEFESA>

Universidade Federal de Pernambuco
Centro de Informática

Guilherme Leite Moreira de Paiva

<TÍTULO DA OBRA>

Trabalho apresentado ao Programa de Graduação em Ciência da Computação do Centro de Informática da Universidade Federal de Pernambuco como requisito parcial para obtenção do grau de Bacharel em Ciência da Computação.

Orientador: *Prof. Dr. George Darmiton*

Recife
<DATA DA DEFESA>

Dedico este trabalho à ...

Agradecimentos

<DIGITE OS AGRADECIMENTOS AQUI>

<DIGITE AQUI A CITAÇÃO>
—<AUTOR> (<NOTA>)

Resumo

<DIGITE O RESUMO AQUI>

Palavras-chave: <DIGITE AS PALAVRAS-CHAVE AQUI>

Abstract

Keywords: <DIGITE AS PALAVRAS-CHAVE AQUI>

Sumário

1	Introdução	1
1.1	Motivação e Contextualização	1
1.1.1	Histórico	1
1.1.2	Combinação de Classificadores	1
1.1.3	Bases Balanceadas e Bases Desbalanceadas	2
1.2	Objetivo	2
1.3	Estrutura do Trabalho	2
2	Combinação de Classificadores	3
2.1	Bagging	3
2.2	Boosting	4
2.2.1	AdaBoost	4
2.3	ICS-Bagging	5

Lista de Figuras

Lista de Tabelas

CAPÍTULO 1

Introdução

Neste capítulo será dada uma introdução à combinação de classificadores bem como uma breve análise dos algoritmos Bagging, Boosting e ICS-Bagging. Para que este assunto seja melhor compreendido, será apresentado o contexto histórico, a motivação do uso de combinação de classificadores e os desafios atuais. Após a seção de motivação e contextualização seguirá um detalhamento deste trabalho, abordando objetivo e estrutura do mesmo.

1.1 Motivação e Contextualização

1.1.1 Histórico

Classificar algo sempre fez parte e é algo que ocorre várias vezes com os seres humanos. Um médico ao diagnosticar um paciente está classificando o mesmo como portador de uma determinada enfermidade ou não, um sommelier ao dar sua opinião sobre um vinho pratica da mesma tarefa. Como podemos ver, a tarefa de classificar algo é de suma importância e nada mais natural que essa tarefa fosse feita por uma máquina. Inicialmente, a abordagem era criar um classificador que pudesse, dado uma instância desconhecida, dizer a qual classe esta instância pertence. No entanto, novamente fazendo analogia ao comportamento humano, ao tomar uma decisão nada mais natural que uma pessoa consulte a opinião de outras pessoas. E isto é a base para se combinar classificadores, a decisão final não é baseada na resposta de um único classificador e sim nas respostas de vários.

1.1.2 Combinação de Classificadores

Na literatura temos vários algoritmos de combinação de classificadores, os primordiais foram: Bagging e Boosting. O algoritmo Bagging introduziu o conceito de bootstrap aggregating, na qual cada classificador é treinado com uma amostra da base de dados, cada classificador é colocado em um conjunto de classificadores e quando uma instância desconhecida é colocada, pelo voto da maioria dos classificadores ou por outro tipo de votação, a instância é classificada como pertencente a uma determinada classe. Já os algoritmos da família Boosting, que tem como algoritmo mais conhecido o AdaBoost, partem de ideia de que se uma instância é classificada de forma errada, esta instância deve ter mais importância e como consequência se uma instância é classificada de forma correta, sua importância é diminuída. A motivação deste algoritmo é termos vários classificadores ditos fracos, mas que são especialistas em um subdomínio do problema. A partir desses algoritmos, que poderíamos chamar de canônicos, vários outros surgiram. Um em especial é o algoritmo ICS-Bagging. Que de forma mais ampla,

combina os classificadores amparado por uma função de *fitness*, de forma que um classificador só é adicionado na *pool* de classificadores se o fato deste classificador ser adicionado na *pool* de classificadores aumenta o *fitness* da *pool*.

1.1.3 Bases Balanceadas e Bases Desbalanceadas

A distribuição de uma classe, ou seja, a proporção de instâncias que pertence a cada classe do conjunto de dados, desempenha um importante papel na combinação de classificadores. Uma base de dados é dita desbalanceado quando o número de instâncias de uma classe é muito maior que o da outra classe. De forma intuitiva, uma base balanceada mantém um proporção mais ou menos igual entre as classes. E este ponto é de suma importância quando se trata de combinação de classificadores pois a abordagem dos algoritmos e as métricas utilizadas diferem quando uma base é desbalanceado ou balanceada.

1.2 Objetivo

O objetivo deste trabalho é analisar diversas métricas de diversidade para o algoritmo ICS-Bagging e avaliar seu desempenho. A medida de desempenho será a área sobre a curva ROC de 5-cross-fold validation de cada base de dados. As bases de dados a serem analisadas são: Glass1, Pima, Iris0, Yeast1, Yeast2, Vehicle2, Vehicle3 e Ecoli1. Todas essas bases são balanceadas e foram obtidas no repositório Keel. No final do trabalho será possível identificar qual métrica obteve o melhor desempenho e qual a melhor proporção da medida de diversidade na função de *fitness* do algoritmo ICS-Bagging.

1.3 Estrutura do Trabalho

O restante deste trabalho possui um capítulo com detalhes sobre diferentes algoritmos de combinação de classificadores bem como uma abordagem mais detalhada do algoritmo ICS-Bagging. Durante o capítulo, será abordado o conceito de métrica de diversidade, bem como várias métricas de diversidade que serão analisadas neste trabalho. Logo após, segue um capítulo mostrando os resultados das análises das diversas métricas de diversidade bem como sua proporção na função de *fitness* bem como uma análise comparativa com algoritmos clássicos. Por fim, será concluído como se dá o comportamento dessas métricas de diversidade e a importância das mesmas na função de *fitness*.

Combinação de Classificadores

Neste capítulo, será mostrado os principais algoritmos de combinação de classificadores, Bagging e Boosting. Cada seção aborda os conceitos básicos de cada algoritmo, o seu pseudo-código e suas características principais, bem como as variações mais conhecidas. Ao final, de maneira mais detalhada, será analisado o algoritmo ICS-Bagging com foco nas possíveis métricas de diversidade que este algoritmo pode usar.

2.1 Bagging

Bagging é um algoritmo [?] de combinação de classificadores que foi desenvolvido com o intuito de melhorar a acurácia na tarefa de classificação. O principal conceito deste algoritmo é o *bootstrap aggregation*, na qual o conjunto de treinamento para cada classificador é construído a partir de uma amostra escolhida aleatoriamente do conjunto de treinamento. Os classificadores são então combinados e ao se apresentar uma nova instância, cada classificador fornece como resultado a classe na qual essa nova instância pertence. Normalmente, a classe que obteve mais votos, é dita como sendo a classe desta instância.

Algorithm 1 Bagging

Dado o conjunto de treinamento T

for all $t = 1, \dots, n$ **do**

 Para cada amostra S do conjunto de treinamento T selecione m exemplos aleatórios com reposição

 Considere h_t o resultado do classificador t para o conjunto de treinamento S

end for

$Resultado \leftarrow$ a maioria dos votos de $(h_1(x), \dots, h_T(x))$

return $Resultado$

Assim, como pode ser observado melhor acima, para cada n interações uma réplica do conjunto de treinamento é criada. E um classificador é treinado com essa réplica, este processo continua até uma quantidade de interações desejada. Após uma quantidade de interações previamente escolhida, uma combinação de classificadores é gerada e a maioria dos votos desses classificadores determina a classe de uma nova instância.

2.2 Boosting

Boosting é um método geral para melhorar a precisão de uma classificação. O objetivo deste método é produzir um classificador forte a partir de um conjunto de vários classificadores fracos. Um classificador é dito fraco quando este tem uma taxa de acerto boa, mas somente para uma porção da base de dados. Por isso a ideia de combinar vários classificadores ditos fracos para formar uma combinação de classificadores que tem uma precisão melhor. Um analogia favorável ao entendimento é que um classificador fraco é um bom classificador para um determinado domínio, e a junção de vários classificadores fracos forma uma combinação de classificadores forte.

Algorithm 2 Boosting

Dado o conjunto de treinamento T

for all $t = 1, \dots, n$ **do**

 Para cada amostra S do conjunto de treinamento T selecione m exemplos aleatórios com reposição

 Considere h_t o resultado do classificador t para o conjunto de treinamento S

end for

Resultado \leftarrow a maioria dos votos de $(h_1(x), \dots, h_T(x))$

return *Resultado*

O método *boosting* treina iterativamente cada classificador atribuindo a cada instância um peso após este treinamento. Os pesos de cada instância são acrescidos quando esta instância é classificada incorretamente e analogamente este peso é decrementado quando classificado corretamente. Isto faz com que cada classificador foque nos exemplos mais difíceis. Depois que a combinação de classificadores for gerada, uma regra de escolha é usada, maioria dos votos por exemplo.

2.2.1 AdaBoost

Um dos mais famosos algoritmos da família *boosting* é o *AdaBoost*, este algoritmo foi a primeira abordagem prática do *Boosting* e hoje é apontando como um dos top dez dos algoritmos de aprendizagem de máquina[94 review] . Este algoritmo utiliza todo o conjunto de dados para treinar cada classificador, mas a cada iteração é dado um foco maior a instâncias difíceis de classificar. O objetivo é classificar corretamente na próxima iteração uma instância que foi classificada de forma errada na iteração atual. Com isso, é dado um foco maior em instâncias que são difíceis de se classificar. Depois de cada iteração, os pesos das instâncias que foram classificadas de forma errada são aumentando; e em contraste, os pesos das instâncias que foram classificadas corretamente são decrementados. Além disso outro peso é atribuído a cada classificador individual, dependendo da sua taxa de acerto na fase de treinamento. Finalmente, quando uma nova instância é apresentada, cada classificador dá um voto, e a classe selecionada foi a que obteve a maioria dos votos. Lembrando que os classificadores possuem pesos diferentes nas votações. O algoritmo pode ser conferido abaixo.

Algorithm 3 AdaBoost

1. **ENTRADA:**1. Conjunto de Treinamento: $\mathcal{D} = \{(x_i, y_i), i = 1, \dots, N\}$, onde $x_i \in \mathbf{R}^d$ e $y_i \in \{-1, +1\}$.1. O número de amostras em cada iteração: m 1. Classificador Fraco: \mathcal{L} that automatically learns a binary classifier $h(x) : \mathbf{R}^d \mapsto \{-1, +1\}$ de um conjunto de treinamento.1. O número de iterações: T 2. **SAÍDA:**2. O Classificador Final: $H(x) = \text{sign}(\sum_{t=1}^T \alpha_t h_t(x))$ 3. **Algorithm**4. Inicialize a distribuição $D_0(i) = 1/N, i = 1, \dots, N$ 5. **for** $t = 1$ até T **do**6. Sample m examples with replacement from \mathcal{D} de acordo com a distribuição $D_{t-1}(i)$.7. Treine o classificador $h_t(x)$ usando os exemplos da amostra8. Compute a taxa de erro $\varepsilon_t = \sum_{i=1}^N D_{t-1}(i) I(h_t(x_i) \neq y_i)$ onde $I(z)$ outputs 1 quando z é verdadeiro e zero caso contrário.9. Saia do loop se $\varepsilon > 0.5$.10. Compute o peso como α_t em

$$\alpha_t = \frac{1}{2} \ln \left(\frac{1 - \varepsilon_t}{\varepsilon_t} \right)$$

11. Atualize a distribuição em as

$$D_t(i) = \frac{1}{Z_t} D_{t-1}(i) \exp(\alpha_t I(y_i \neq h_t(x_i)))$$

where $Z_t = \sum_{i=1}^N D_{t-1}(i) \exp(\alpha_t I(y_i \neq h_t(x_i)))$.12. **end for**13. Construct the final classifier $H(x) = \text{sign}(\sum_{t=1}^T \alpha_t h_t(x))$.

2.3 ICS-Bagging

Este algoritmo é o ponto central e objetivo de estudo deste trabalho. Por isso um maior grau de detalhamento se faz necessário.

